

Smart Split Bill AI

Prototype aplikasi web berbasis Streamlit untuk membaca foto nota secara OCR-free, mengekstrak data transaksi, dan membagi tagihan kepada beberapa orang.

Created by: Hami Ahqafi

Eksperimen dilakukan pada dua foto nota nyata dengan dua vision-language model. Raw output, waktu inference, dan tabel ringkasan disimpan pada [docs/results](#).

Daftar Isi

- [Latar Belakang](#)
- [Fitur Prototype](#)
- [Struktur Project](#)
- [Instalasi dan Menjalankan Aplikasi](#)
- [Riset dan Perbandingan Model](#)
- [Menjalankan Eksperimen Dua Nota](#)
- [Contoh Hasil Pembacaan](#)
- [Alasan Pemilihan Model](#)
- [Evaluasi Model Pembaca Bill](#)
- [Evaluasi Produk Web](#)
- [Pengujian](#)
- [Keamanan](#)

Latar Belakang

Smart Split Bill dikembangkan sebagai proof of concept untuk membantu pengguna:

1. Mengubah foto nota menjadi data transaksi terstruktur.
2. Memeriksa dan mengoreksi hasil pembacaan AI.
3. Menentukan orang yang menikmati setiap item.
4. Membagi pajak, service charge, diskon, dan biaya lainnya.
5. Memastikan total tagihan semua orang sama persis dengan total pada nota.

Fitur Prototype

- Upload nota dalam format JPG, JPEG, PNG, atau WebP.

- Pembacaan nota menggunakan model vision tanpa EasyOCR atau PyTesseract.
- Dukungan Hugging Face Inference Providers, Groq Vision, dan OpenAI Vision.
- Ekstraksi:
 - nama merchant;
 - nama item;
 - jumlah item;
 - harga per item;
 - total harga item;
 - subtotal;
 - pajak, service charge, diskon, dan biaya tambahan;
 - total bill.
- Hasil ekstraksi dapat diedit untuk mengatasi kesalahan AI.
- Peringatan otomatis jika jumlah item, subtotal, charges, dan total bill tidak konsisten secara aritmetika.
- Input beberapa peserta.
- Satu item dapat dipilih oleh satu atau beberapa peserta.
- Biaya tambahan dibagi proporsional berdasarkan nilai item yang dikonsumsi.
- Penanganan sisa pembulatan secara deterministik.
- Validasi bahwa jumlah tagihan seluruh peserta sama dengan total bill.
- Download hasil pembagian dalam format JSON.
- Mode demo jika API tidak tersedia.

Struktur Project

```

.
├── app.py                                # Antarmuka Streamlit
├── smart_split/
│   ├── ai.py                            # Integrasi model vision
│   ├── models.py                        # Normalisasi data receipt
│   ├── splitter.py                      # Algoritma pembagian bill
│   └── scripts/
│       ├── benchmark_models.py         # Benchmark dua model pada dua nota
│       └── docs/
│           ├── receipts/               # Simpan dua foto nota di sini
│           └── results/                # Output benchmark tersimpan di sini
├── tests/
│   └── test_splitter.py
├── submission/
│   ├── Smart_Split_Bill_README.pdf
│   └── Smart_Split_Bill_Experiment.ipynb
├── requirements.txt
└── .env.example
  
```

File pada folder submission/ dapat langsung diunggah ke Google Drive.

Instalasi dan Menjalankan Aplikasi

1. Clone repository

```
git clone <URL_REPOSITORY_GITHUB>
cd smart-split-bill-ai
```

2. Buat virtual environment

Python 3.11 atau 3.12 direkomendasikan.

```
python3.12 -m venv venv312
source venv312/bin/activate
```

Untuk Windows:

```
venv312\Scripts\activate
```

3. Install dependency

```
pip install -r requirements.txt
```

4. Siapkan API token

```
cp .env.example .env
```

Isi salah satu provider pada .env:

```
HF_TOKEN=hf_your_token
GROQ_API_KEY=gsk_your_key
OPENAI_API_KEY=sk_your_key
OPENAI_MODEL=gpt-4.1-mini
```

Untuk Hugging Face, gunakan fine-grained token dengan izin **Make calls to Inference Providers**. Jangan mengunggah .env ke GitHub.

5. Jalankan Streamlit

```
streamlit run app.py
```

Buka <http://localhost:8501>.

Riset dan Perbandingan Model

Assignment mensyaratkan minimal dua model OCR-free. Model yang dibandingkan:

Model 1 — Qwen3-VL-8B-Instruct

- Model ID: Qwen/Qwen3-VL-8B-Instruct:fastest
- Jenis: vision-language model.
- Eksekusi: Hugging Face Inference Providers.

- Alasan diuji:
- dapat menerima gambar dan instruksi teks secara langsung;
- dapat diminta menghasilkan JSON sesuai schema;
- ukuran lebih kecil daripada varian Qwen VL yang lebih besar;
- sesuai untuk nota dengan format yang bervariasi.

Model 2 — Aya Vision 32B

- Model ID: CohereLabs/aya-vision-32b:fastest
- Jenis: multilingual vision-language model.
- Eksekusi: Hugging Face Inference Providers.
- Alasan diuji:
- kemampuan multilingual relevan untuk nota Indonesia;
- dapat membaca gambar sekaligus mengikuti instruksi ekstraksi;
- menjadi pembandingan model yang lebih besar terhadap Qwen3-VL-8B.

Model tambahan yang dipertimbangkan

naver-clova-ix/donut-base-finetuned-cord-v2 adalah model OCR-free yang di-fine-tune untuk receipt pada dataset CORD. Model ini sangat relevan secara domain, tetapi umumnya perlu dijalankan secara lokal/Colab atau menggunakan endpoint khusus. Donut dapat dijadikan eksperimen lanjutan untuk membandingkan model khusus receipt dengan vision-language model general-purpose.

Kriteria evaluasi

Kriteria	Cara evaluasi
Kelengkapan item	Bandingkan jumlah item ground truth dan hasil model
Nama item	Periksa apakah teks utama item terbaca benar
Quantity	Bandingkan jumlah item per baris
Harga	Bandingkan unit price dan total item
Komponen bill	Periksa subtotal, pajak, service, diskon, dan total
Konsistensi aritmetika	Periksa subtotal dan total terhadap komponennya
Validitas output	Periksa apakah output dapat diparsing sebagai JSON
Kecepatan	Catat durasi inference setiap gambar dalam detik
Stabilitas	Catat error API, output kosong, atau format tidak konsisten

Menjalankan Eksperimen Dua Nota

1. Tambahkan gambar

Simpan dua foto nota sebagai:

```
docs/receipts/receipt_1.jpg
docs/receipts/receipt_2.jpg
```

Gambar sebaiknya fokus, terang, dan tidak memuat data pribadi sensitif.

2. Jalankan benchmark

```
python scripts/benchmark_models.py \
docs/receipts/receipt_1.jpg \
docs/receipts/receipt_2.jpg
```

Script akan menjalankan dua model pada dua gambar yang sama dan menyimpan:

```
docs/results/benchmark_results.json
docs/results/model_comparison.csv
```

Setiap hasil berisi nama model, nama gambar, durasi inference, status, dan data receipt yang berhasil diekstrak. File ini dapat langsung disertakan dalam repository sebagai bukti eksperimen.

Contoh Hasil Pembacaan

Ground truth dibuat dengan membaca nota secara manual, kemudian dibandingkan dengan output model. Detail ground truth tersedia di [ground_truth.json](#), sedangkan output lengkap model tersedia di [benchmark_results.json](#).

Nota 1



Nota Tom Sushi memiliki sembilan baris transaksi dengan total quantity 23.

Field	Ground truth	Qwen3-VL-8B	Aya Vision 32B
Baris item	9	9	10
Baris item tepat	9	8	6
Subtotal	Rp369.000	Rp369.000	Rp1.845.000
Service charge	Rp18.450	Rp18.450	Rp92.250
Pajak	Rp38.745	Rp38.745	Rp184.500
Total	Rp426.195	Rp426.195	Rp2.121.750
Waktu inference	-	12,380 detik	17,506 detik

Temuan kualitatif:

- Qwen menemukan semua baris, merchant, subtotal, biaya tambahan, dan total.
- Qwen salah menafsirkan satu baris Co ld Ocha: harga total Rp6.000 dianggap

sebagai harga satuan sehingga total item menjadi Rp12.000.

- Nama Chx Karaage Mental Rice terbaca sebagai Chx Karage Mental Rice.
- Aya mengalami *column shifting* mulai bagian bawah daftar. Nilai Blue, Black, dan subtotal berpindah menjadi harga satuan/total item, sehingga hasil aritmetika akhirnya jauh dari nota.

Nota 2



Nota Santuy Mart memiliki tujuh jenis item. Foto berisi anotasi putih 3 pcs x 8000, 24000, 76000, dan 100000. Nilai Rp100.000 adalah uang yang dibayarkan, bukan total transaksi.

Field	Ground truth	Qwen3-VL-8B	Aya Vision 32B
Baris item	7	7	6
Baris item tepat	7	7	5
Subtotal	Rp76.000	Rp76.000	Rp76.000
Biaya tambahan	Rp0	Rp0	Rp0
Total bill	Rp76.000	Rp100.000	Rp76.000

Field	Ground truth	Qwen3-VL-8B	Aya Vision 32B
Waktu inference	-	10,971 detik	11,045 detik

Temuan kualitatif:

- Qwen menemukan seluruh tujuh item beserta quantity dan harga dengan tepat.
- Qwen menganggap angka anotasi 100000/paid amount sebagai total bill, walaupun subtotal item sudah benar Rp76.000.

- Aya menghasilkan subtotal dan total yang benar, tetapi menggabungkan

Kaki Tiga Kaleng Jeruk dan Larutan Cap Kaki Tiga Strawberry. Akibatnya hanya enam baris yang dikembalikan.

- Anotasi pada gambar terbukti dapat membantu membaca bagian tertutup, tetapi juga berpotensi mengubah interpretasi model.

Ringkasan komparasi

Model	Rata-rata inference	Kelengkapan item	Akurasi summary bill
Qwen3-VL-8B	11,68 detik	15/16 baris tepat	1 nota sepenuhnya tepat; 1 salah total
Aya Vision 32B	14,28 detik	11/16 baris tepat	1 nota tepat; 1 gagal berat

Qwen sekitar **18,2% lebih cepat** dalam eksperimen ini. Angka tersebut adalah latency end-to-end melalui Hugging Face Inference Providers, sehingga turut dipengaruhi jaringan, antrean provider, dan cold start.

Alasan Pemilihan Model

Model yang dipilih untuk prototype adalah Qwen/Qwen3-VL-8B-Instruct : fastest.

Pemilihan ini didasarkan pada hasil eksperimen:

1. Mendukung input gambar tanpa pipeline OCR eksternal.
2. Mampu mengikuti prompt dan menghasilkan struktur JSON yang dibutuhkan UI.
3. Menghasilkan 15 dari 16 baris item dengan benar, dibanding Aya 11 dari 16.
4. Membaca nota Tom Sushi yang lebih padat secara jauh lebih stabil.
5. Rata-rata inference 11,68 detik, sekitar 18,2% lebih cepat dari Aya.
6. Ukuran 8B lebih efisien dibanding model pembanding 32B.
7. Dapat digunakan melalui Hugging Face Inference Providers sehingga deployment

Streamlit tidak perlu memuat model besar di RAM lokal.

Kelemahan Qwen pada total nota kedua ditangani pada produk dengan menyediakan editor hasil ekstraksi dan peringatan otomatis jika jumlah item, subtotal, charges, dan total bill tidak konsisten. Prompt juga membedakan TOTAL dari CASH/PAID AMOUNT, meskipun eksperimen menunjukkan prompt saja belum selalu cukup untuk

gambar yang memiliki anotasi besar.

Evaluasi Model Pembaca Bill

Kelebihan

- OCR-free: gambar diproses langsung oleh vision-language model.
- Schema prompt membuat hasil lebih mudah dipakai aplikasi.
- Provider API mengurangi kebutuhan GPU lokal.
- Output masih dapat dikoreksi pengguna jika model melakukan kesalahan.

Kelemahan

- Model dapat salah membaca font kecil, nota buram, singkatan, atau kolom yang berhimpitan.
- Model dapat menukar harga satuan dengan total item.
- Qwen salah membedakan total bill dengan paid amount pada nota kedua.
- Aya mengalami column shifting pada nota pertama dan menggabungkan dua produk pada nota kedua.
- Output JSON dari model generatif tidak selalu konsisten.
- Latency dan ketersediaan bergantung pada provider eksternal.
- Model general-purpose tidak secara khusus dilatih untuk semua format receipt Indonesia.
- Evaluasi dua gambar masih terlalu kecil untuk menyimpulkan performa umum.
- Hasil antar-run dapat berubah meskipun temperature dibuat nol karena routing provider dan implementasi model tidak selalu deterministik.

Ide perbaikan

- Tambahkan preprocessing: auto-rotate, crop, perspective correction, contrast, dan resize.
- Jika `total != subtotal + charges`, tampilkan peringatan dan minta model melakukan ekstraksi ulang khusus pada bagian total.
- Gunakan constrained/structured generation jika provider mendukung JSON schema.
- Fine-tune Donut atau model document understanding pada nota Indonesia.
- Bangun dataset uji dengan variasi minimarket, restoran, e-commerce, font, kondisi cahaya, dan tingkat kemiringan.

- Tambahkan confidence score dan tandai field yang perlu diperiksa pengguna.
- Gunakan retry prompt khusus ketika schema atau aritmetika tidak valid.

Evaluasi Produk Web

Kelebihan

- Alur aplikasi mengikuti proses pengguna: upload, verifikasi, pilih peserta, assign item, dan lihat total.
- Semua field hasil model dapat diedit.
- Satu item dapat dibagi kepada beberapa orang.
- Pajak dan service dibagi proporsional terhadap konsumsi.
- Algoritma memakai integer unit terkecil sehingga pembulatan tidak membuat total akhir berbeda dari total bill.
- Terdapat mode demo dan export JSON.

Kelemahan dan potensi bug

- Belum ada autentikasi atau penyimpanan riwayat transaksi.
- State akan hilang ketika session Streamlit berakhir.
- Assignment peserta masih dilakukan per item, belum mendukung pembagian quantity yang berbeda dalam satu baris.
- Biaya tambahan saat ini dibagi proporsional; beberapa kasus mungkin membutuhkan pembagian rata atau aturan khusus.
- Belum ada export PDF, gambar ringkasan, atau share link.
- Pengguna masih perlu memahami dan menyediakan API token.
- Belum ada deployment publik dan pengujian multi-user.

Ide perbaikan

- Tambahkan database untuk riwayat bill.
- Sediakan pilihan pembagian biaya: proporsional, rata, atau custom.
- Tambahkan split berdasarkan quantity, persentase, dan nominal manual.
- Tambahkan login serta link bill yang dapat dibagikan.
- Tambahkan export PDF/WhatsApp-friendly summary.
- Terapkan validasi schema dan indikator field bermasalah pada UI.
- Deploy ke Streamlit Community Cloud atau platform container.
- Tambahkan integration test untuk upload gambar hingga hasil pembagian.

Pengujian

Jalankan:

```
pytest -q
```

Test saat ini mencakup:

- pembagian nominal yang tidak habis dibagi;
- rekonsiliasi total seluruh peserta dengan total bill;
- pembagian diskon bernilai negatif.

Keamanan

- File `.env` masuk `.gitignore`.
- `.env.example` hanya berisi placeholder.
- API token tidak boleh ditulis di source code, notebook, screenshot, output, issue GitHub, atau README.
- Jika token pernah terpublikasi, revoke dan buat token baru.

Lisensi dan Penggunaan

Project ini dibuat sebagai proof of concept assignment. Periksa lisensi dan ketentuan penggunaan setiap model sebelum penggunaan produksi.